

Физически обоснованное раннее предупреждение о квантовой декогеренции при неизвестной нестационарной скорости диссипации

Статус документа. Это пояснительный черновик на русском языке, а не публикация. Авторитетные источники результатов — статьи `paper/paper_1/main.tex` (1 кубит, сценарии A–C) и `paper/paper_2/paper2.tex` (2 кубита, сценарии D/E); при расхождении верны они. Числа ниже сверены с `experiments/results/*.csv` по состоянию на сентябрь 2026; у каждой таблицы указан эксперимент-источник.

Содержание

1 Проблема	2
2 Когда задача нетривиальна	2
2.1 Случай постоянного γ : аналитическое решение	2
2.2 Случай переменного $\gamma(t)$: реалистичная ситуация	3
3 Отличие от существующих подходов	3
4 Архитектура: Physics-Informed Residual BiLSTM	4
4.1 Ключевая идея	4
4.2 Детали архитектуры	4
4.3 Ablation-варианты (эксперимент E1)	5
5 Физические системы и параметризация $\gamma(t)$	6
5.1 Поддерживаемые системы	6
5.2 Параметризация $\gamma(t)$ полиномами Бернштейна	6
6 Эксперименты и результаты	6
6.1 E1 — Ablation: компоненты архитектуры	6
6.2 E2 — Минимальное окно наблюдения	7
6.3 E3 — Устойчивость к шуму измерений	7
6.4 E4 — Кросс-системное обобщение	8
7 Место в литературе и научный вклад	8
7.1 Отличие от PINNs	8
7.2 Вклады работы	9

1 Проблема

Квантовые компьютеры, квантовые сенсоры и системы квантовой связи принципиально ограничены явлением **декогеренции** — необратимой потерей квантовой когерентности из-за взаимодействия системы с окружающей средой.

Математически открытая квантовая система описывается уравнением Линдблада:

$$\dot{\rho} = -i[H, \rho] + \gamma(t) \sum_k \left(L_k \rho L_k^\dagger - \frac{1}{2} \{L_k^\dagger L_k, \rho\} \right), \quad (1)$$

где ρ — матрица плотности, H — гамильтониан, L_k — операторы прыжков, а $\gamma(t) \geq 0$ — нестационарная скорость диссипации.

Оператор прыжка σ_- . Для двухуровневой системы $\{|0\rangle, |1\rangle\}$ оператор амплитудного затухания (канал релаксации) задаётся матрицей:

$$\sigma_- = |0\rangle\langle 1| = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}.$$

Он переводит кубит из возбуждённого состояния $|1\rangle$ в основное $|0\rangle$ — моделирует спонтанное излучение или релаксацию в термостат при нулевой температуре. Подставляя $L = \sigma_-$ в уравнение Линдблада и раскрывая скобки:

$$\sigma_- \rho \sigma_+ - \frac{1}{2} (\sigma_+ \sigma_- \rho + \rho \sigma_+ \sigma_-), \quad \sigma_+ = (\sigma_-)^\dagger = \begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix},$$

получаем уравнения на элементы ρ :

$$\dot{\rho}_{11} = -\gamma \rho_{11}, \quad \dot{\rho}_{01} = -\frac{\gamma}{2} \rho_{01}.$$

Отсюда $\rho_{01}(t) = \rho_{01}(0) e^{-\gamma t/2}$, и когерентность убывает как $C(t) \propto e^{-\gamma t/2}$.

Для фазовой релаксации используется другой оператор — σ_z (диагональная матрица $\text{diag}(1, -1)$), который не меняет населённости, но уничтожает когерентность вдвое быстрее: $\dot{\rho}_{01} = -\gamma \rho_{01}$, то есть $T_2 = 1/\gamma$.

Время декогеренции T_2 — это момент, когда ℓ_1 -когерентность (сумма модулей внедиагональных элементов матрицы плотности) падает до e^{-1} от начального значения.

Знание T_2 наперёд — или, точнее, оценка *оставшегося* времени до декогеренции из неполной ранней траектории — напрямую полезно: оно позволяет системам квантовой коррекции ошибок заблаговременно сбросить или перекодировать кубит до критического падения верности.

2 Когда задача нетривиальна

2.1 Случай постоянного γ : аналитическое решение

Здесь $C(t)$ — ℓ_1 -когерентность матрицы плотности (сумма модулей всех внедиагональных элементов $\sum_{i \neq j} |\rho_{ij}|$); для однокубитной системы это просто $2|\rho_{01}(t)|$. При $C = 0$ система полностью декогерирована.

Если γ постоянна и используется канал амплитудного затухания (σ_-), когерентность убывает экспоненциально:

$$C(t) = C_0 e^{-\gamma t/2} \implies \frac{d \log C}{dt} = -\frac{\gamma}{2} \implies T_2 = \frac{2}{\gamma} = -\frac{1}{\text{slope}},$$

где slope — наклон $\log C(t)$ по МНК на любом участке траектории до декогеренции.

Мы проверили: эта формула даёт $R^2 = 0,9995$ и MAE = 0,056 на тестовой выборке. **Машинное обучение здесь не нужно.**

2.2 Случай переменного $\gamma(t)$: реалистичная ситуация

На любой физической платформе скорость диссипации нестационарна:

Платформа	Источник нестационарного $\gamma(t)$
Сверхпроводящие кубиты	1/ f -флуктуации потока, TLS-флуктуаторы
Спиновые кубиты	Сверхтонкое взаимодействие с ядерным спин-резервуаром
Ионные ловушки	Дрейф мощности лазера, флуктуации микродвижения
Фотонные системы	Дрейф скорости утечки из резонатора

В этих условиях наклон МНК даёт лишь *локальную* оценку текущего $\gamma(t)/2$, и предсказанное T_2 может быть систематически смещено — в зависимости от формы профиля $\gamma(t)$ (монотонный рост/спад, пик, ступенька и т. д.).

Задача становится принципиально нетривиальной: никакой аналитической формулы общего вида нет. Именно здесь нужен обученный предиктор.

3 Отличие от существующих подходов

Ближайшая родственная работа — arXiv:2505.06928 (*Phys. Rev. A*, 2025) — использует Transformer для **обратной задачи**: восстановления $\gamma(t)$ из *полной* траектории. Это офлайн-подход, неприменимый в режиме реального времени.

Характеристика	arXiv:2505.06928	Наша работа
Цель	Восстановить $\gamma(t)$	Предсказать T_2
Тип задачи	Обратная (офлайн)	Раннее предупреждение (онлайн)
Вход	Полная траектория	Ранний частичный отрезок
Выход	Коэффициенты Бернштейна	T_2 + score риска
Физика	Отсутствует	МНК-наклон встроен как prior
Аналитический предел	Нет	Восстанавливает формулу при $\gamma=\text{const}$

Наш подход — **прямой и онлайнный**: предсказание из первых $\approx 15\text{--}20\%$ траектории, без необходимости знать $\gamma(t)$ или запускать полное моделирование.

4 Архитектура: Physics-Informed Residual BiLSTM

4.1 Ключевая идея

Сеть не предсказывает T_2 с нуля. Она предсказывает **поправку** δT к аналитической оценке:

$$\hat{T}_{2,\text{rem}} = \underbrace{T_{\text{physics}}(\mathbf{w})}_{\text{МНК-оценка}} + \underbrace{\delta T_{\text{LSTM}}(\mathbf{w})}_{\text{выученная коррекция}}. \quad (2)$$

Это принципиально иное, чем классические PINN (Raissi et al., 2019), где физика входит как *штраф в функцию потерь* и теоретически может быть проигнорирована достаточно гибкой сетью. Здесь физика входит как **архитектурный inductive bias**: выход сети структурно декомпозирован на физическую часть и выученную поправку. Это гарантирует:

1. **Graceful degradation**: при $\gamma = \text{const}$ физическая формула точна, поэтому сеть учит $\delta T \approx 0$ и вся система деградирует к аналитическому решению.
2. **Corrective capacity**: при переменном $\gamma(t)$ физический prior даёт смещённую, но сильную оценку — сеть корректирует только остаток. Это намного проще, чем предсказывать T_2 напрямую.

4.2 Детали архитектуры

Вход. Временной ряд наблюдаемых за окно длины $W = 20$ шагов: $\langle \sigma_x \rangle$, $\langle \sigma_y \rangle$, $\langle \sigma_z \rangle$, ℓ_1 -когерентность, чистота — плюс их логарифмические преобразования ($F = 7$ для 1-кубитных, $F = 10$ для 2-кубитных систем после нулевого дополнения).

Энкодер. Двухнаправленный LSTM (hidden 64, 1 слой) $\rightarrow$ mean-pooling $\rightarrow$ вектор размерности 128.

Физические скаляры. Четыре числа вычисляются аналитически по окну: наклон

МНК ($\approx -\gamma/2$), $\log C$ в конце окна, текущее время t_{obs} , оценка T_{physics} . Конкатенируются к LSTM-эмбедингу: итого 132 измерения.

Головы.

- *Regression head*: $\text{Linear}(64) \rightarrow \text{GELU} \rightarrow \text{Linear}(1) \rightarrow \delta T$. Итог: $T_{\text{physics}} + \delta T$.
- *Risk head*: $\text{Linear}(32) \rightarrow \text{GELU} \rightarrow \text{Linear}(1) \rightarrow \text{sigmoid} \rightarrow p_{\text{risk}}$.

Score риска p_{risk} . Помимо регрессии T_2 , сеть параллельно решает задачу бинарной классификации: грозит ли декогеренция в ближайшем будущем? Метка $y_{\text{risk}} \in \{0, 1\}$ формируется автоматически из симуляции: $y_{\text{risk}} = 1$, если оставшееся время до декогеренции меньше порогового. Выход $p_{\text{risk}} \in [0, 1]$ — вероятность этого события, получаемая через сигмоиду из выхода *risk head*.

Обучение. Совместная функция потерь:

$$\mathcal{L} = \underbrace{\mathcal{L}_{\text{Huber}}(\delta T, \delta T^*)}_{\text{регрессия поправки}} + \underbrace{\mathcal{L}_{\text{BCE}}(p_{\text{risk}}, y_{\text{risk}})}_{\text{бинарная классификация}}, \quad (3)$$

где $\delta T^* = T_2^* - T_{\text{physics}}$ — истинная поправка (цель регрессии).

Huber loss (робастная регрессия):

$$\mathcal{L}_{\text{Huber}}(x, x^*) = \begin{cases} \frac{1}{2}(x - x^*)^2, & |x - x^*| \leq \delta, \\ \delta(|x - x^*| - \frac{\delta}{2}), & |x - x^*| > \delta. \end{cases}$$

При малых ошибках ведёт себя как MSE (квадратичный штраф), при больших — как MAE (линейный), что снижает влияние выбросов по сравнению с чистым MSE.

BCE (бинарная кросс-энтропия):

$$\mathcal{L}_{\text{BCE}}(p, y) = -y \log p - (1 - y) \log(1 - p).$$

Стандартная функция потерь для задач бинарной классификации: штрафует за уверенные неправильные предсказания сильнее, чем за неуверенные.

Оптимизатор AdamW, планировщик reduce-on-plateau, ранняя остановка по валидационному лоссу (patience = 25 эпох).

4.3 Ablation-варианты (эксперимент E1)

Вариант	Описание
physics_only	Только формула МНК, без нейронной сети
lstm_only	BiLSTM без физического prior ($T_{\text{physics}} = 0$)
physics_lstm	Полная residual-архитектура (наш метод)
transformer	Чистый Transformer, аналог arXiv:2505.06928

5 Физические системы и параметризация $\gamma(t)$

5.1 Поддерживаемые системы

Сцен.	Система	Гамильтониан	Операторы прыжков
A	1q	$H = \omega\sigma_z$	σ_- , $\gamma=\text{const}$
B	1q	$H = \omega\sigma_z$	σ_- , TD $\gamma(t)$
C	1q	$H = \omega\sigma_z$	σ_z , TD $\gamma(t)$
D	2q XXZ	$J(\sigma^x\sigma^x + \sigma^y\sigma^y + \sigma^z\sigma^z)$	σ_- на каждый
E	2q TFIM	$J\sigma^x\sigma^x + h(\sigma^z + \sigma^z)$	σ_- на каждый

5.2 Параметризация $\gamma(t)$ полиномами Бернштейна

Для гарантированно неотрицательного $\gamma(t) \geq 0$ при любых параметрах используются полиномы Бернштейна 4-й степени с неотрицательными коэффициентами. В обучающей выборке используются шесть качественно различных форм: постоянная, монотонно возрастающая/убывающая, пик, ступенька вверх/вниз.

6 Эксперименты и результаты

6.1 E1 — Ablation: компоненты архитектуры

Одно- и двухкубитные сценарии измерялись *разными* экспериментами с разными настройками, поэтому приводятся отдельно — объединять их в одну таблицу было бы некорректно.

(a) Сценарии A–C — эксперимент E1 (100 траекторий на сценарий, источник: e1_ablation_p1.csv; Paper 1, табл. E1):

Вариант	A	B	C
physics_only	0,999	0,753	0,965
lstm_only	−0,446	0,009	−0,029
physics_lstm	0,976	0,945	0,976
transformer	0,799	0,902	0,981

(б) Сценарии D, E — эксперимент E6a (500 траекторий на сценарий, adaptive prior $\tau = 0,7$; источник: e6_ablation_improved.csv; Paper 2, табл. E6a):

Вариант	D (XXZ)	E (TFIM)
physics_only	−0,687	−4,267
lstm_only	0,673	0,377
physics_lstm	0,636	0,455
transformer	0,897	0,689

(Метрика: R^2 , выше — лучше.)

Выводы:

- **Сценарий А:** `physics_only` $R^2 = 0,999$ — аналитическая формула практически точна при постоянном γ . ML не добавляет ничего. Это *подтверждает* физическую состоятельность prior.
- **Сценарии В, С:** `physics_lstm` превосходит `physics_only` на В (0,945 vs 0,753) и слегка — на С (0,976 vs 0,965). Ключевое: `lstm_only` проваливается на всех трёх сценариях (−0,446, 0,009, −0,029), то есть физический prior *необходим*, а не просто полезен.
- **Сценарии D, E:** OLS-формула даёт $R^2 < 0$ (−0,687 и −4,267) — для 2-кубитных систем когерентность не является простой экспонентой из-за запутанности. Adaptive prior выправляет ситуацию: `physics_lstm` даёт 0,636 (D) и 0,455 (E).
- **Transformer доминирует на двух кубитах** (0,897 на D и 0,689 на E) — в отличие от однокубитного случая, где `physics_lstm` сильнее. Там, где физический prior структурно неверен, гибкость self-attention выгоднее; это зафиксировано в Paper 2 как *опровержение* переноса residual-архитектуры на 2 кубита.

6.2 E2 — Минимальное окно наблюдения

$f = t_{\text{obs}}/T_2$	R^2	MAE	AUROC
0,05	0,711	0,825	0,933
0,10	0,723	0,813	0,950
0,15	0,735	0,773	0,947
0,20	0,736	0,702	0,872
0,30	0,734	0,677	0,969
0,50	0,697	0,674	0,990

(Источник: `e2_window_sweep_p1.csv`; смесь сценариев В+С.)

Примечательно: **AUROC $\geq 0,93$ уже при $f = 0,05$** — сигнал тревоги о скорой декогеренции работает уже через 5% траектории. R^2 остаётся примерно постоянным (0,70–0,74) при всех f : узкое место — ёмкость обучения и смешение режимов В и С, а не информационное содержание окна (на одном сценарии В модель достигает 0,945 при том же $W = 20$). Заявлять $R^2 \geq 0,95$ по этим данным нельзя — раннее предупреждение здесь является *классификационным* результатом (AUROC), а не регрессионным.

6.3 E3 — Устойчивость к шуму измерений

σ	R^2	MAE	AUROC
0,000	0,959	0,220	0,976
0,010	0,956	0,224	0,976
0,020	0,949	0,251	0,971
0,050	0,901	0,374	0,942
0,100	0,727	0,597	0,865

(Источник: `e3_noise_sweep_p1.csv`, $N = 74$.)

При реалистичном уровне шума $\sigma = 0,05$ модель держит $R^2 = 0,901$ и AUROC = 0,942. Деградация от $\sigma = 0$ до $\sigma = 0,10$: $\Delta R^2 = -0,232$, $\Delta \text{AUROC} = -0,111$ — при $\sigma = 0,10$ AUROC опускается до 0,865, что мы считаем практическим потолком шумоустойчивости текущей архитектуры. **Физический prior обеспечивает встроенную устойчивость к шуму**: OLS-наклон усредняет шум по W точкам ($\sim \sqrt{W}$ подавление), BiLSTM дополнительно использует temporal pooling.

6.4 E4 — Кросс-системное обобщение

Единой модели сразу на все пять сценариев в текущих результатах нет. Кросс-системное обобщение меряется двумя отдельными прогонами: на однокубитной смеси (A, B, C) и на двухкубитной (D, E).

(а) **Смесь A+B+C, physics_lstm** (источник: e4_cross_system_p1.csv; Paper 1, табл. E4):

Сценарий	Система	R^2	MAE	AUROC
A	1q σ_- , $\gamma=\text{const}$	0,490	1,164	0,979
B	1q σ_- , TD γ	0,867	0,397	0,981
C	1q σ_z , TD γ	0,936	0,162	0,990

(б) **Смесь D+E, Transformer**, эксперимент E11a (окно $L = 20$, min-gap = 10, 500 траекторий на сценарий; Paper 2):

Сценарий	Система	R^2	MAE	AUROC
D	2q XXZ, TD γ	0,817	0,616	0,937
E	2q TFIM, TD γ	0,566	0,900	0,888

Одна модель покрывает свою группу систем без переобучения. На сценарии A модель хуже специализированного аналитического метода (0,490 vs 0,999) — ожидаемо при обобщении: при постоянном γ физический член уже точен, и обученная на смеси сеть зря добавляет ненулевую поправку δT . На TFIM (E) $R^2 = 0,566$ — цель 0,70 не взята. В Paper 2 это объясняется структурным потолком, а не недообучением: диссипатор не коммутирует с оператором чётности и потому мешает два симметричных сектора, тем сильнее, чем ближе их временные масштабы. Формулировку «потолок *вблизи фазового перехода*» пришлось уточнить: репликация J-скана на трёх сидах (R5) не подтвердила провал, локализованный у $J \approx h$, — минимум кочует по сидам, а сама точка перехода ничем не выделяется. Устоял монотонный спад предсказуемости с ростом связи, чего теория и требует: отношение расщеплений $r(J)$ растёт монотонно и пика в $J = h$ не имеет.

7 Место в литературе и научный вклад

7.1 Отличие от PINNs

Классические PINN [1] включают физику в функцию потерь в виде штрафа за нарушение дифференциального уравнения. Наш подход принципиально отличается: физика входит как **жёсткий архитектурный prior** — выход сети структурно задан как $T_{\text{physics}} + \delta T_{\text{LSTM}}$. Преимущества:

- Физический prior не может быть «проигнорирован» сетью при оптимизации.
- В аналитически точном пределе ($\gamma = \text{const}$) модель гарантированно деградирует к точному решению при $\delta T \rightarrow 0$.
- Сеть работает в значительно сниженном пространстве поиска (только остаток), что ускоряет сходимость и снижает потребность в данных.

7.2 Вклады работы

1. **Чёткая граница применимости ML:** показано, что ML нужен только при нестационарном или многокубитном режиме; при постоянном $\gamma + \sigma_-$ аналитика точна ($R^2 \approx 1$).
2. **Residual-архитектура с физическим prior:** встроенная МНК-оценка гарантирует аналитический предел и улучшает выборочную эффективность.
3. **Онлайн-применимость:** эффективный alarm уже при $f = 0,05$ (AUROC $\geq 0,92$).
4. **Встроенная устойчивость к шуму:** OLS-усреднение по окну подавляет измерительный шум архитектурно.
5. **Калиброванный score риска:** p_{risk} напрямую пригоден для интеграции в системы квантовой коррекции ошибок.

Ключевые зависимости: `qutip`, `torch`, `numpy`, `scikit-learn`, `gradio` (интерактивный UI).

Список литературы

- [1] M. Raissi, P. Perdikaris, G. E. Karniadakis. Physics-informed neural networks. *J. Comput. Phys.*, 378:686–707, 2019.